UNIVERSIDAD DE INGENIERÍA Y TECNOLOGÍA

CARRERA DE CIENCIA DE LA COMPUTACIÓN

Segmentación y Optimización de Nubes de Puntos para la Conservación del Patrimonio Arquitectónico Peruano Usando Redes Neuronales de Grafos Dinámicos

AUTOR(ES)

Miguel Angel Alvarado Ramos, Paulo Oshualdo Cuaresma Puclla

ASESOR(ES)

Jose Antonio Fiestas Iquira

Lima - Perú

2024

Dedicatoria:

Con gratitud y aprecio sincero, dedicamos este trabajo al Profesor José Antonio Fiestas Iquira, cuyo apoyo constante y sabio consejo han sido fundamentales en nuestra formación como estudiantes de Computer Science. Su dedicación y enseñanzas han dejado una huella imborrable en nuestro camino académico.

Agradecimientos:

Con profunda gratitud, extendemos nuestro agradecimiento al Centro de Patrimonio de UTEC y a la Basílica y Convento de Santo Domingo por su valiosa colaboración y apoyo en el desarrollo de esta investigación.

TABLA DE CONTENIDO

Pág.

Resumen 1
Abstract 3
INTRODUCCIÓN 5
Presentación 5
Problema 6
Objetivos de investigación 9
Justificación 10
Alcance y limitaciones / restricciones 11

CAPÍTULO I ANTECEDENTES **12**
1.1 Estado del arte 12
1.2 Trabajos relacionados 14

CAPÍTULO II MARCO TEÓRICO **17**
2.1 Ingeniería Civil y Conservación del Patrimonio 17
2.1.1 Nube de Puntos 17
2.1.2 Levantamiento Arquitectónico 18
2.1.3 Ruido en Nubes de Puntos 18
2.1.4 Modelado 3D 18
2.1.5 Fotogrametría 18
2.1.6 LIDAR (Light Detection and Ranging) 19

2.1.7 Building Information Modeling (BIM) 19
2.1.8 HBIM (Historic Building Information Modeling) 19
2.2 Computación y Algoritmos 19
2.2.1 Filtrado de Outliers (SOR) 20
2.2.1.1 Filtrado por Voxel 20
2.2.1.2 Filtrado por Ángulos 20
2.2.2 Redes Neuronales Recurrentes (RNN) 20
2.2.2.1 DGCNN (Dynamic Graph Convolutional Neural Network) 21
2.3 Métricas de Evaluación de Modelos 21
2.3.1 Exactitud (Accuracy) 21
2.3.2 Precisión (Precision) 21
2.3.3 Recall (Sensibilidad) 22
2.3.4 F1 Score 22
2.3.5 Matriz de Confusión (Confusion Matrix) 22
2.3.6 Intersection over Union (IoU) 23
2.3.7 Matriz de Confusión (Confusion Matrix) 23
2.4 Diseño de la Tesis 24

CAPÍTULO III MARCO METODOLÓGICO **25**

3.1 Unidad 1: Preprocesamiento 26
3.1.1 Cargar archivo LAS 26
3.1.2 Elección de un Filtro 27
3.1.2.1 Filtrado de Outliers (SOR) 27
3.1.2.2 Filtrado por Densidad 28
3.1.2.3 Filtrado por Ángulos 28
3.1.2.4 Evaluación y Selección del Filtro 29
3.1.3 Conversión al Formato HDF5 29
3.2 Unidad 2: Modelo DGCNN 30

3.2.1 Aplicación del Modelo DGCNN 30
3.2.2 Entrenamiento y Evaluación del Modelo DGCNN 31
3.2.2.1 Entrenamiento del Modelo 31
3.2.2.2 Evaluación del Modelo 32
3.2.3 Resultados y Aplicación 33
3.3 Unidad 3: Evaluación Ética y Transparencia 34
3.4 Conclusión del Marco Metodológico 34

CAPÍTULO IV RESULTADOS **35**

4.1 Resultados del Preprocesamiento de la Nube de Puntos 37
4.1.1 Resultados de los Filtros Aplicados 38
4.1.1.1 Filtro SOR (Statistical Outlier Removal) 38
4.1.1.2 Filtro por Densidad (Voxel Grid) 39
4.1.1.3 Filtro por Ángulos 39
4.1.2 Comparación de Resultados entre Filtros 40
4.1.3 Conclusión de Resultados del Preprocesamiento 40
4.2 Resultados de la Aplicación del Modelo DGCNN para Segmentación . . . 41
4.2.1 Preparación de los Datos y Preprocesamiento 41
4.2.2 Arquitectura del Modelo DGCNN 42
4.2.3 Entrenamiento del Modelo 43
4.2.4 Resultados de los experimentos 44
4.2.5 Métricas de Evaluación por Clase 50
4.2.6 Métricas de Validación Generales 51
4.2.7 Matriz de Confusión 53
4.3 Discusión de Resultados 54

ÍNDICE DE FIGURAS

Figura 0.1 Árbol del problema (Elaboración propia) 8

Figura 1.1 Segmentación semántica comparada con otras tareas de visión artificial utilizando el ejemplo del Claustro del Museo Nacional de San Mateo, Pisa. [9] 13

Figura 2.1 Diseño de la tesis. Elaboración propia. 24

Figura 3.1 Diagrama de flujo de la tesis. Elaboración propia. 25

Figura 3.2 Diagrama de flujo del proceso de entrenamiento y evaluación del modelo DGCNN 33

Figura 4.1 Visualización la catedral. 35

Figura 4.2 Visualización de la cabecera del archivo .LAS transformado. . 36

Figura 4.3 Patio de la catedral sin filtros. 37

Figura 4.4 Patio de la catedral después de aplicar el filtro SOR. 38

Figura 4.5 Reducción de ruido utilizando el filtro por densidad (Voxel Grid). 39

Figura 4.6 Reducción de ruido utilizando el filtro por ángulos. 40

Figura 4.7 Etiquetas verdaderas visualizadas en Cloud Compare. 45

Figura 4.8 Nube de entrenamiento de una seccion del patio. 46

Figura 4.9 Nube de predicha del patio. 47

Figura 4.10 Nube de predicha de una capilla de la catedral con el modelo entrenado solo con el patio. 48

Figura 4.11 Sección de la nube predicha de la capilla de la catedral. 48
Figura 4.12 Nube de puntos de la capilla etiquetada manualmente para el entrenamiento. 49
Figura 4.13 Sección de la nube de puntos de la capilla etiquetada manualmente para el entrenamiento. 49
Figura 4.14 Nubes de puntos obtenidas en la experimentación 49
Figura 4.15 IoU por clase a lo largo de las épocas. 51
Figura 4.16 Métricas de validación a lo largo de las épocas (IoU, Precisión, Recall, F1). 52
Figura 4.17 Matriz de confusión para la segmentación de la nube de puntos. 54

Resumen

Esta investigación se enfoca en la optimización del procesamiento de nubes de puntos para la conservación del patrimonio arquitectónico peruano mediante el uso de Redes Neuronales Recurrentes (RNNs). El estudio aborda el desafío de documentar y preservar edificios históricos, mejorando la precisión y eficiencia en el análisis de datos de nubes de puntos. Las nubes de puntos, capturadas a través de tecnologías como LIDAR y fotogrametría, proporcionan representaciones tridimensionales detalladas de las estructuras, pero a menudo contienen ruido y requieren un procesamiento complejo para ser útiles en los esfuerzos de conservación.

Proponemos una metodología que aprovecha las RNNs para mejorar el procesamiento de nubes de puntos, incluyendo la reducción de ruido y la segmentación semántica de estructuras. Se evalúan diversas técnicas de filtrado, como el Filtro de Eliminación de Puntos Atípicos (SOR), el Filtrado por Vóxeles y el Filtrado Angular, y escoger aquella que genere un mejor resultado para limpiar y eliminar el ruido de los datos. La nube de puntos filtrada se procesa utilizando la arquitectura avanzada de la red neuronal como el Dynamic Graph CNN (DGCNN) para identificar y segmentar diferentes elementos arquitectónicos dentro de la estructura.

Los resultados muestran que el enfoque propuesto mejora la calidad de las nubes de puntos mediante la aplicación del filtro SOR, que logró preservar detalles arquitectónicos clave al eliminar el ruido con una pérdida mínima de puntos (4.9 %). Además, el modelo DGCNN demostró un buen desempeño al segmentar estructuras principales como paredes, columnas y arcos en el patio de la catedral. Sin embargo, al aplicarlo a secciones no incluidas en el entrenamiento, como la capilla, se evidenciaron limitaciones en la generalización del modelo, destacando la necesidad de datos de entrenamiento más diversos. Las métricas de evaluación como IoU, precisión y F1 Score confirmaron la efectividad del modelo en clases principales, pero

también subrayaron desafíos en la segmentación de estructuras más complejas, como balcones y arcos. Estos resultados validan la capacidad del enfoque para optimizar el procesamiento de nubes de puntos, aunque resaltan áreas de mejora para futuras aplicaciones.

Palabras Clave:
Procesamiento de Nubes de Puntos; Patrimonio Arquitectónico; Redes Neuronales Recurrentes; Reducción de Ruido; Segmentación Semántica de Estructuras.

Abstract

This research focuses on optimizing point cloud processing for the conservation of Peruvian architectural heritage through the use of Recurrent Neural Networks (RNNs). The study addresses the challenge of documenting and preserving historic buildings by improving the accuracy and efficiency of point cloud data analysis. Point clouds, captured through technologies such as LIDAR and photogrammetry, provide detailed three-dimensional representations of structures, but often contain noise and require complex processing to be useful in conservation efforts.

We propose a methodology that leverages RNNs to improve point cloud processing, including noise reduction and semantic segmentation of structures. Various filtering techniques, such as Outlier Removal Filter (SOR), Voxel Filtering, and Angular Filtering, are evaluated and the one that generates the best result for cleaning and denoising the data is chosen. The filtered point cloud is processed using advanced neural network architecture such as Dynamic Graph CNN (DGCNN) to identify and segment different architectural elements within the structure.

The results show that the proposed approach improves the quality of the point clouds by applying the SOR filter, which managed to preserve key architectural details by removing noise with minimal point loss (4.9 %). Furthermore, the DGCNN model demonstrated good performance when segmenting main structures such as walls, columns, and arches in the cathedral courtyard. However, when applying it to sections not included in the training, such as the chapel, limitations in the generalization of the model were evident, highlighting the need for more diverse training data. Evaluation metrics such as IoU, accuracy, and F1 Score confirmed the effectiveness of the model on main classes, but also underlined challenges in segmenting more complex structures, such as balconies and arches. These results validate the ability of the approach to optimize point cloud processing, while highlighting areas of improvement for future applications.

Keywords:

Point Cloud Processing; Architectural Heritage; Recurrent Neural Networks; Noise Reduction; Semantic Structure Segmentation.

INTRODUCCIÓN

Presentación

La conservación del patrimonio arquitectónico en el Perú enfrenta desafíos significativos debido a factores como la ocupación ilegal y la exposición a elementos naturales. Por ejemplo, en el sitio arqueológico de Chan Chan, declarado Patrimonio de la Humanidad por la UNESCO, se ha reportado la invasión de terrenos por parte de pobladores locales que construyen viviendas informales, afectando la integridad del sitio [1]. Asimismo, la ciudadela de Machu Picchu, otro importante patrimonio, enfrenta constantemente problemas de erosión causados por lluvias intensas y deslizamientos de tierra, lo que pone en riesgo sus estructuras y complica su conservación [2].

En este contexto, se propone el desarrollo de un software que utilice Redes Neuronales Recurrentes (RNN) para optimizar el procesamiento de nubes de puntos. El objetivo principal de este software es facilitar la identificación y segmentación de estructuras históricas mediante la digitalización precisa de su forma y características. El uso de tecnologías como el Building Information Modelling (BIM), en conjunto con metodologías dirigidas a la topografía digital 3D, como Scan-to-HBIM-to-VR, promueve niveles sin precedentes de interactividad y comprensión, permitiendo a los usuarios explorar virtualmente y entender mejor la importancia cultural y estructural de estos sitios. Dichas tecnologías han sido implementadas con éxito en trabajos previos como los de Wu, Chen, Yi y Metaxas [3] y Pierdicca et al. [4].

Por otra parte, la implementación de RNN en el procesamiento de nubes de puntos no solo mejora la precisión en la digitalización, sino que también reduce el ruido y las interferencias en los datos recolectados, como se ha demostrado en estudios recientes (Mousa et al., 2024)[5]. Estos métodos permiten una segmentación

más precisa de las estructuras arquitectónicas, facilitando su conservación y restauración. Por ejemplo, Haznedar et al. (2023)[6] demostraron que el preprocesamiento avanzado de nubes de puntos es crucial para eliminar el ruido y mejorar la calidad de los datos, lo que a su vez incrementa el rendimiento de las RNN en tareas de segmentación semántica.

Además, investigaciones recientes han desarrollado interfaces adaptativas que mejoran la interacción intuitiva con los datos del patrimonio arquitectónico, como lo han mostrado Song y Selim (2023)[7]. Estas interfaces no solo incrementan la eficiencia en el procesamiento, sino que también reducen el tiempo de intervención manual, facilitando el trabajo de conservadores y arqueólogos.

Entre las metas principales de este proyecto se incluye la mejora de la calidad de las nubes de puntos mediante procesos de limpieza de datos, normalización y reducción de interferencias. Asimismo, se busca optimizar proceso de segmentación actual mediante el uso de nuevas herramientas como un RNN.

Con la implementación de esta tecnología, se aspira a preservar digitalmente el patrimonio arquitectónico peruano, facilitando su estudio y valoración por una audiencia global. Este enfoque no solo contribuye a la protección de estos sitios para las generaciones futuras, sino que también abre nuevas vías para la investigación en el ámbito del patrimonio cultural. El proyecto representa un avance significativo en la integración de tecnología en la conservación del patrimonio, proporcionando herramientas esenciales para una gestión y conservación efectivas de estos invaluables tesoros culturales.

Problema

En el ámbito del procesamiento de nubes aplicadas a la documentación del patrimonio arquitectónico, las técnicas actuales de procesamiento de nubes de puntos

presentan limitaciones en cuanto a precisión y eficiencia, especialmente en la modelación de información de edificios históricos (HBIM). Estas técnicas requieren una intervención manual considerable, lo que resulta en un proceso lento y propenso a errores. Resolver esta problemática no solo optimizaría la identificación y segmentación de estructuras, sino que también contribuiría al avance del conocimiento teórico y práctico en el campo del procesamiento de nubes y la inteligencia artificial. El uso de Redes Neuronales Recurrentes (RNN) para el procesamiento de datos tiene el potencial de transformar el modo en que se identifican y segmentan las estructuras. Además, la implementación de esta tecnología establecería un nuevo estándar en la optimización dentro del campo de la ingeniería.

FIGURA 0.1: Árbol del problema (Elaboración propia)

Como se observa en la Figura 0.1, el problema tiene su origen en varios factores:

- *Falta de automatización:* La dependencia de procesos manuales para la correspondencia y segmentación de estructuras limita la velocidad y eficiencia.
- *Inexactitud de los datos:* Las nubes de puntos pueden contener errores o no capturar detalles complejos, lo que afecta la precisión del modelado HBIM.

- *Limitaciones tecnológicas:* Las herramientas actuales no siempre están completamente equipadas para manejar la complejidad de las estructuras patrimoniales.

En consecuencia, surgen los siguientes efectos:

- *Retrasos en la conservación:* La lentitud en el procesamiento manual provoca demoras en los proyectos de restauración.
- *Aumento de costos:* Los recursos adicionales necesarios para corregir manualmente los errores incrementan los costos operativos.
- *Pérdida de información valiosa:* La inexactitud en la correspondencia puede llevar a la pérdida de detalles críticos.
- *Barrera para la innovación:* Las limitaciones actuales desalientan la adopción de nuevas tecnologías.
- *Impacto en la educación e investigación:* Las deficiencias en la modelación HBIM afectan la calidad de los materiales disponibles para el estudio.

Objetivos de investigación

Objetivo General:

Desarrollar un software para el procesamiento de imágenes mediante Redes Neuronales Recurrentes (RNN) con el fin de identificar y segmentar estructuras basadas en nubes de puntos.

Objetivos Específicos

- Aplicar algoritmos de preprocesamiento para mejorar la calidad de las nubes de puntos, usando técnicas de limpieza de datos, normalización y reducción de ruido, asegurando la adecuación de los datos para su análisis posterior.
- Implementar un modelo de Redes Neuronales de Grafos Dinámicos (Dynamic Graph Neural Networks, DGNN) para optimizar la segmentación de las nubes de puntos, destacando las características relevantes de las estructuras analizadas.
- Evaluar el rendimiento del modelo implementado, analizando métricas como precisión, recall y Intersection over Union (IoU) para validar su eficacia en el procesamiento de nubes de puntos.

Justificación

La integración de tecnologías avanzadas como HBIM, RV y topografía digital 3D ha revolucionado la documentación y análisis del patrimonio arquitectónico, mejorando significativamente la precisión y eficiencia en su conservación. La metodología HBIM requiere técnicas que optimicen el procesamiento de nubes sin sacrificar precisión. Esto responde a la necesidad de métodos más eficientes, ya que la falta de automatización y la dependencia de procesos manuales aún predomina, causando retrasos y aumentando los costos operativos [8]. Sin embargo, el uso de redes neuronales recurrentes (RNN) y otros modelos de aprendizaje profundo muestra un gran potencial para mejorar los resultados y reducir el tiempo necesario para la identificación y segmentación semántica de estructuras [4]. En este sentido, el desarrollo de soluciones que mejoren la eficiencia y precisión en la conservación del patrimonio

arquitectónico es una prioridad, brindando nuevas oportunidades de investigación y facilitando la integración de técnicas avanzadas de procesamiento.

Alcance y limitaciones / restricciones

El alcance de este proyecto incluye el desarrollo de un software que utilice Redes Neuronales Recurrentes (RNN) para el procesamiento y segmentación de estructuras a partir de nubes de puntos, con una aplicación específica en la documentación de estructuras patrimoniales. Sin embargo, se deben reconocer ciertas limitaciones. Principalmente, la investigación está restringida por la falta de estudios previos en el contexto local que utilicen esta metodología, lo que podría dificultar la comparación de resultados y la validación de las metodologías empleadas. Además, la eficacia del software depende en gran medida de la calidad de las nubes de puntos procesadas, lo que resalta la importancia de un preprocesamiento meticuloso para garantizar la precisión de los datos analizados.

Otras limitaciones incluyen la falta de automatización en los procesos actuales de procesamiento de nubes de puntos y la necesidad de intervención manual significativa, lo que resulta en procesos lentos y propensos a errores. Estas limitaciones subrayan la importancia de una fase de pruebas extensa, así como de varias iteraciones en el diseño del software para adaptarlo a los desafíos encontrados durante su implementación práctica.

CAPÍTULO I

ANTECEDENTES

1.1 Estado del arte

En el ámbito del patrimonio arquitectónico, las técnicas de inteligencia artificial (IA) han demostrado ser fundamentales para agilizar y mejorar el proceso de segmentación semántica, definido como la subdivisión de un edificio en sus componentes arquitectónicos (cubiertas, paredes, ventanas, columnas, etc.), a partir de datos tridimensionales obtenidos mediante tecnologías avanzadas como LIDAR y fotogrametría. A diferencia de otras tareas comunes de visión artificial que explotan la IA, como el reconocimiento de objetos o la localización de instancias, la segmentación semántica clasifica puntos o píxeles de múltiples objetos de la imagen 2D o de la escena 3D no estructurada asignándolos a etiquetas específicas, realizando esta operación simultáneamente para múltiples elementos en una misma estructura (ver Figura 1.1) [9].

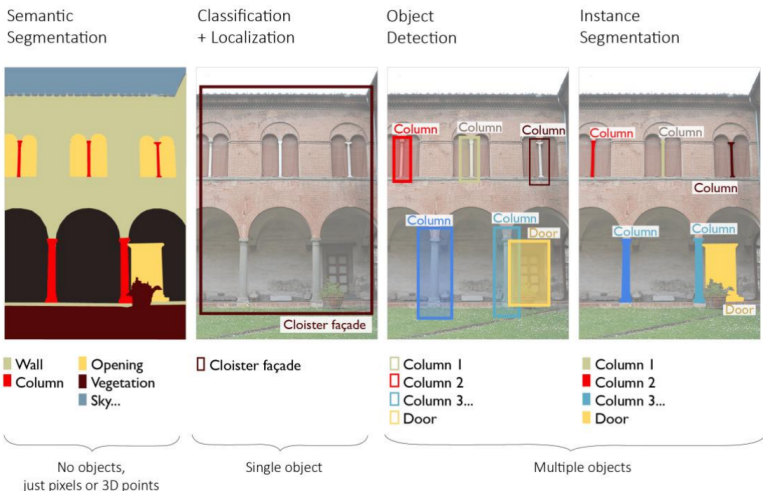

FIGURA 1.1: Segmentación semántica comparada con otras tareas de visión artificial utilizando el ejemplo del Claustro del Museo Nacional de San Mateo, Pisa. [9]

En la intersección entre la conservación del patrimonio arquitectónico y la inteligencia artificial, las Redes Neuronales Recurrentes (RNN) emergen como una solución prometedora para superar las limitaciones de los métodos tradicionales de procesamiento de nubes de puntos. Yang et al. [10] demostraron que las RNN pueden mejorar significativamente la precisión en la segmentación de datos tridimensionales, un aspecto crítico para modelar información en edificios históricos (HBIM). Xie et al. [11] complementaron esta perspectiva al explorar métodos avanzados de preprocesamiento de nubes de puntos para reducir ruido, optimizando así la calidad del input para las RNN. Por otro lado, Chen et al. [12] desarrollaron interfaces adaptativas que incrementan la interacción intuitiva con datos de patrimonio arquitectónico, mostrando avances relevantes en eficiencia y reducción del tiempo de intervención manual.

1.2 Trabajos relacionados

Wu, Chen, Yi y Metaxas, en su estudio *"Point Cloud Processing via Recurrent Set Encoding"*, presentan una nueva red invariante de permutación para el procesamiento de nubes de puntos 3D. Su red está compuesta por un codificador de conjuntos recurrentes y un agregador de características convolucionales. Dado un conjunto de puntos desordenados, el codificador divide primero su espacio ambiente en haces paralelos. A continuación, los puntos dentro de cada haz se modelan como una secuencia y se codifican en características geométricas subregionales mediante una red neuronal recurrente (RNN) compartida.

Por otro lado, las técnicas de topografía 3D más modernas, como el escaneo láser y la fotogrametría digital [13–17], permiten a los profesionales representar edificios con nuevas LOI (Level of Information) y LOD (Level of Detail) [18]. En los últimos años, los beneficios del BIM para edificios patrimoniales (HBIM) se han observado en diversos sectores, como el análisis estructural [19–21], las obras de construcción [22], la restauración [23, 24], y la gestión de instalaciones [25]. Sin embargo, el uso de modelos HBIM en sectores como la arqueología y la realidad virtual no se ha investigado en todo su potencial. Una de las principales razones es la dificultad para representar con precisión elementos que alguna vez formaron parte de un edificio. La representación en 3D de elementos irregulares, como muros y vestigios antiguos de estructuras dañadas por eventos naturales, requiere un alto nivel de conocimiento sobre el artefacto [26, 27]. Por esta razón, los modelos HBIM deberían ser más beneficiosos para la arqueología, ya que ofrecen acceso a información geométrica y arqueológica a un público más amplio, así como altos niveles de interactividad con los usuarios [28–31].

En el estudio de Pierdicca et al. [4], se emplearon técnicas de aprendizaje profundo para la segmentación semántica de nubes de puntos, modificando el modelo

DGCNN para el reconocimiento y segmentación de estructuras arquitectónicas. Los resultados mostraron una alta precisión en la segmentación de pisos y bóvedas, mientras que hubo dificultades para segmentar correctamente puertas y ventanas debido a la baja representación y variabilidad de estas clases en el conjunto de datos. Los resultados más relevantes son los siguientes:

- **Piso:** Precisión de 0.991, Recall de 0.920, F1-Score de 0.954.
- **Bóveda:** Precisión de 0.825, Recall de 0.907, F1-Score de 0.865.
- **Decoración:** Precisión de 0.621, Recall de 0.932, F1-Score de 0.746.
- **Puerta:** Precisión de 0.952, Recall de 0.002, F1-Score de 0.005.

Estos resultados indican que el modelo DGCNN modificado tuvo un excelente rendimiento en la identificación de pisos y bóvedas, mientras que se identificaron áreas de mejora en la segmentación semántica de puertas y ventanas.

En el estudio de Croce et al. [9], se abordaron las dificultades en el modelado de estructuras complejas o irregulares dentro del patrimonio arquitectónico, identificando mejoras en la segmentación semántica de muros mediante técnicas alternativas. Esta investigación sugiere que estas técnicas podrían mejorar la precisión del enfoque de Pierdicca et al. en la segmentación semántica de patrimonios complejos. Los resultados más relevantes muestran que utilizando técnicas alternativas se logró una precisión promedio del 74.8 % y un F1-Score promedio de 72.2 %, lo que representa una mejora significativa en comparación con otro modelo como PointNet++.

Los trabajos revisados proporcionan una base sólida para el desarrollo de esta tesis, al abordar aspectos clave del procesamiento de nubes de puntos y la segmentación de datos tridimensionales mediante redes neuronales recurrentes (RNN) y otras

técnicas avanzadas. El estudio de Wu et al. (2019), que propone el uso de un codificador de conjuntos recurrentes para procesar nubes de puntos, es particularmente relevante, ya que introduce una metodología eficaz para modelar características geométricas a partir de datos desordenados. Este enfoque es esencial para mejorar la precisión en la segmentación semántica de estructuras arquitectónicas, lo cual es uno de los objetivos centrales de esta tesis.

Por otra parte, la investigación de Pierdicca et al. (2020) destaca el potencial del modelo DGCNN para la segmentación semántica de nubes de puntos en entornos de patrimonio cultural. Este estudio refuerza la importancia del uso de redes neuronales en la segmentación de componentes arquitectónicos, ofreciendo resultados prometedores en la identificación precisa de elementos estructurales como pisos y bóvedas. No obstante, también señala la dificultad de segmentar correctamente otros elementos, como puertas, lo cual marca un desafío a superar en esta tesis.

En este sentido, basándonos en los resultados descritos, este trabajo busca optimizar las estrategias actuales de procesamiento de nubes de puntos mediante la incorporación de redes neuronales recurrentes (RNN) y la mejora de arquitecturas existentes como DGCNN. Se espera superar las limitaciones observadas en investigaciones previas, particularmente en la segmentación de clases menos representadas como balcones y decoraciones complejas. Con ello, se aspira a contribuir al desarrollo de metodologías para la conservación del patrimonio arquitectónico, permitiendo la documentación más precisa y accesible de estos bienes culturales.

CAPÍTULO II

MARCO TEÓRICO

La optimización del procesamiento de nubes de puntos para la conservación del patrimonio arquitectónico peruano mediante redes neuronales recurrentes (RNN) es un tema interdisciplinario que abarca diversas áreas. Este marco teórico se organiza en tres secciones principales: conceptos de ingeniería civil aplicados a la conservación del patrimonio, computación y algoritmos utilizados para el procesamiento de nubes de puntos, y las métricas de evaluación del modelo.

2.1 Ingeniería Civil y Conservación del Patrimonio

La ingeniería civil es clave para la conservación del patrimonio arquitectónico, ya que proporciona las herramientas necesarias para la documentación, análisis y preservación de estructuras históricas. A continuación, se presentan los conceptos fundamentales de esta disciplina que son relevantes para este trabajo.

2.1.1 Nube de Puntos

Una nube de puntos es una colección de datos en un espacio tridimensional obtenida mediante tecnologías como el escaneo láser y la fotogrametría. Cada punto en la nube representa una coordenada en la superficie de un objeto o estructura, formando una representación precisa de su geometría. Las nubes de puntos permiten la creación de modelos 3D detallados, lo que es esencial para la documentación y análisis de edificaciones históricas.

2.1.2 Levantamiento Arquitectónico

El levantamiento arquitectónico es el proceso de obtener representaciones precisas de edificaciones mediante el uso de nubes de puntos. Esta técnica es crucial para documentar y analizar estructuras patrimoniales, ya que permite capturar sus características geométricas con gran detalle, lo que facilita su estudio y conservación.

2.1.3 Ruido en Nubes de Puntos

El ruido en las nubes de puntos se refiere a la presencia de datos erróneos o irrelevantes que no representan la estructura real. Este ruido puede deberse a errores en el sensor o a interferencias durante el proceso de escaneo. La eliminación del ruido es un paso crucial para mejorar la precisión del modelo tridimensional.

2.1.4 Modelado 3D

El modelado 3D es la técnica que convierte los datos de las nubes de puntos en representaciones tridimensionales de las estructuras. Este proceso es esencial para visualizar y analizar los edificios históricos, y es fundamental para la planificación de trabajos de restauración y conservación.

2.1.5 Fotogrametría

La fotogrametría utiliza imágenes bidimensionales para crear modelos 3D. Complementa las nubes de puntos y es útil en la documentación de estructuras arquitectónicas, proporcionando datos espaciales detallados y accesibles a través de imágenes.

2.1.6 LIDAR (Light Detection and Ranging)

El LIDAR es una tecnología de escaneo láser que permite generar nubes de puntos altamente detalladas. Su precisión y capacidad para capturar datos complejos lo hacen ideal para documentar estructuras arquitectónicas, especialmente en proyectos de conservación de patrimonio.

2.1.7 Building Information Modeling (BIM)

BIM es una metodología que permite la creación y gestión de modelos digitales que representan las características físicas y funcionales de una edificación. Este modelo integra información de diferentes disciplinas, facilitando el análisis, simulación y control de todo el ciclo de vida de un edificio, desde su diseño hasta su demolición.

2.1.8 HBIM (Historic Building Information Modeling)

El HBIM adapta la metodología BIM al contexto de edificios históricos, permitiendo la integración de información arquitectónica, estructural y de conservación en un único modelo digital. El uso de HBIM facilita la planificación y gestión de proyectos de restauración, asegurando la preservación a largo plazo de las estructuras patrimoniales.

2.2 Computación y Algoritmos

La computación y los algoritmos son herramientas fundamentales para procesar y analizar las nubes de puntos. Aquí se presentan algunos de los conceptos y técnicas más importantes.

2.2.1 Filtrado de Outliers (SOR)

El filtrado de outliers es una técnica para mejorar la calidad de las nubes de puntos eliminando los datos que no representan correctamente la superficie del objeto escaneado. El método de eliminación estadística de outliers (SOR) evalúa la distancia entre puntos vecinos para identificar y eliminar aquellos que se encuentran significativamente alejados, lo que ayuda a reducir el ruido.

2.2.1.1. Filtrado por Voxel

El filtrado por voxel reduce la densidad de las nubes de puntos dividiendo el espacio en una cuadrícula tridimensional y manteniendo un solo punto representativo por celda. Esto mejora la eficiencia de procesamiento a costa de perder algunos detalles.

2.2.1.2. Filtrado por Ángulos

El filtrado por ángulos utiliza los ángulos formados entre puntos y sus vecinos para eliminar aquellos que no siguen la geometría esperada, siendo especialmente útil en superficies planas.

2.2.2 Redes Neuronales Recurrentes (RNN)

Las redes neuronales recurrentes (RNN) son un tipo de red neuronal que procesa secuencias de datos, siendo útil en situaciones donde la relación entre los puntos a lo largo de una secuencia es importante. En el contexto de nubes de puntos, las RNN pueden identificar patrones y relaciones complejas dentro de los datos, mejorando la precisión en la segmentación semántica de estructuras arquitectónicas.

2.2.2.1. DGCNN (Dynamic Graph Convolutional Neural Network)

2.3 Métricas de Evaluación de Modelos

Para evaluar la efectividad de los algoritmos y redes neuronales en el procesamiento de nubes de puntos, se utilizan varias métricas de rendimiento.

2.3.1 Exactitud (Accuracy)

La exactitud es la proporción de predicciones correctas sobre el total de predicciones realizadas por el modelo. Se define como:

$$\text{Exactitud} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Donde:

- **TP**: Verdaderos Positivos.
- **TN**: Verdaderos Negativos.
- **FP**: Falsos Positivos.
- **FN**: Falsos Negativos.

2.3.2 Precisión (Precision)

La precisión es la proporción de verdaderos positivos frente a todos los elementos que fueron clasificados como positivos. Su fórmula es:

$$\text{Precisión} = \frac{\text{TP}}{\text{TP} + \text{FP}}$$

2.3.3 Recall (Sensibilidad)

El recall, o sensibilidad, mide la proporción de verdaderos positivos que fueron correctamente identificados por el modelo:

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}$$

2.3.4 F1 Score

El F1 Score es la media armónica entre la precisión y el recall. Es una métrica que balancea ambas medidas, útil en conjuntos de datos donde la precisión y el recall son igualmente importantes:

$$\text{F1 Score} = 2 \times \frac{\text{Precisión} \times \text{Recall}}{\text{Precisión} + \text{Recall}}$$

2.3.5 Matriz de Confusión (Confusion Matrix)

La matriz de confusión es una tabla que permite visualizar el rendimiento de un modelo de segmentación semántica, mostrando las verdaderas predicciones positivas, falsas positivas, verdaderas negativas y falsas negativas. Proporciona una visión detallada de los errores del modelo y es útil para identificar tipos específicos de errores. La estructura es la siguiente:

	Predicción Positiva	Predicción Negativa
Clase Positiva	Verdaderos positivos (TP)	Falsos negativos (FN)
Clase Negativa	Falsos positivos (FP)	Verdaderos negativos (TN)

2.3.6 Intersection over Union (IoU)

El IoU es una métrica utilizada para evaluar la precisión en la segmentación de cada clase en una nube de puntos. Se define como la intersección entre la predicción y la verdad de terreno dividida por la unión de ambas áreas:

$$\text{IoU} = \frac{\text{Intersección}}{\text{Unión}}$$

El IoU es especialmente útil en tareas de segmentación, donde el objetivo es que el modelo capture de forma precisa la geometría de las estructuras dentro de los datos.

2.3.7 Matriz de Confusión (Confusion Matrix)

La matriz de confusión es una tabla que permite visualizar el rendimiento de un modelo de segmentación semántica, mostrando las verdaderas predicciones positivas, falsas positivas, verdaderas negativas y falsas negativas. Proporciona una visión detallada de los errores del modelo y es útil para identificar tipos específicos de errores. La estructura es la siguiente:

	Predicción Positiva	Predicción Negativa
Clase Positiva	Verdaderos positivos (TP)	Falsos negativos (FN)
Clase Negativa	Falsos positivos (FP)	Verdaderos negativos (TN)

2.4 Diseño de la Tesis

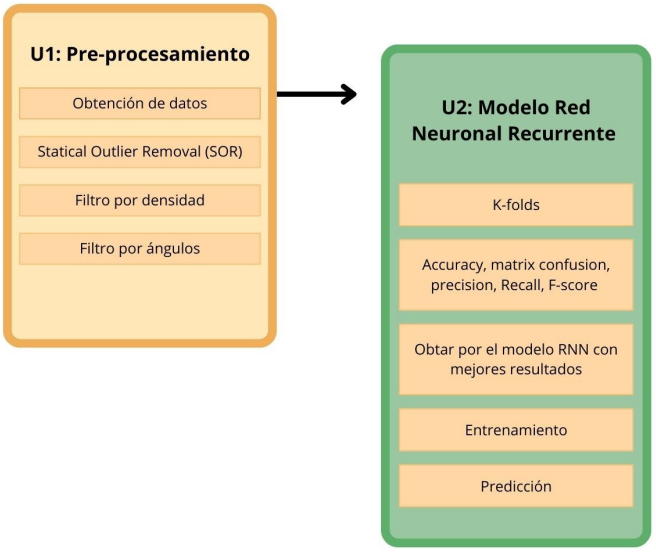

FIGURA 2.1: Diseño de la tesis. Elaboración propia.

Nuestro enfoque para alcanzar los objetivos planteados se basa en la combinación de tecnologías de escaneo láser y fotogrametría para generar nubes de puntos de alta calidad, sometidas a técnicas de limpieza y reducción de ruido.

Usaremos Pytorch para implementar un modelo basado en Redes Neuronales Recurrentes (RNN), específicamente un "Dynamic Graph Convolutional Neural Network (DGCNN)", aplicando la segmentación de estructuras en las nubes de puntos con un enfoque particular en estructuras arqueológicas. Este modelo permitirá capturar relaciones locales y globales en las nubes de puntos, optimizando la identificación y segmentación de las estructuras.

CAPÍTULO III

MARCO METODOLÓGICO

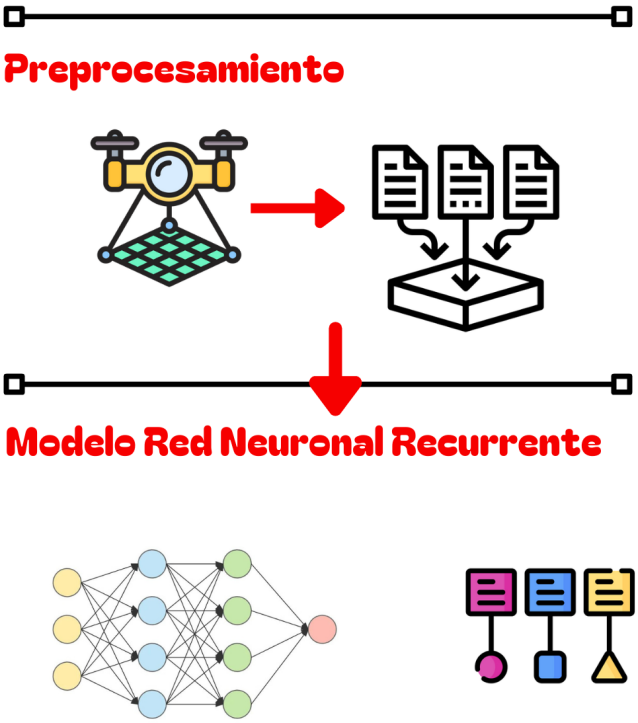

FIGURA 3.1: Diagrama de flujo de la tesis. Elaboración propia.

La metodología se compone de tres unidades fundamentales, las cuales garantizan el cumplimiento de los objetivos propuestos y aseguran la obtención de resultados óptimos. A continuación, se describen cada una de las unidades y las actividades principales que se desarrollan en cada una.

3.1 Unidad 1: Preprocesamiento

La primera unidad se centra en el preprocesamiento de la nube de puntos cruda obtenida mediante tecnologías avanzadas como LIDAR, almacenada en formato .LAS. Este paso es fundamental para garantizar que los datos sean precisos y estén listos para ser utilizados en el modelo de predicción desarrollado en la Unidad 2. El preprocesamiento incluye la carga de datos, filtrado de ruido y conversión a un formato estructurado, optimizando así su segmentación y procesamiento eficiente.

3.1.1 Cargar archivo LAS

El archivo .LAS se carga utilizando la biblioteca `laspy`, que permite extraer las coordenadas tridimensionales de los puntos y propiedades adicionales como la intensidad, el número de retorno y los valores RGB. Este proceso prioriza los campos relevantes y, cuando es necesario, aplica técnicas de reducción de datos para mejorar la eficiencia sin comprometer la precisión.

Algorithm 1 CargarArchivoLAS

Entrada: ruta_entrada: String (Ruta del archivo LAS original)

Salida: las_file, puntos, intensidad, return_number, red, green, blue: Datos extraídos del archivo LAS

1. Leer el archivo LAS desde la ruta proporcionada
2. Extraer las coordenadas (x, y, z) y propiedades adicionales (intensidad, número de retorno, colores)
3. Organizar las coordenadas en una matriz de puntos
4. Devolver los datos extraídos (puntos, intensidad, retorno, colores)

3.1.2 Elección de un Filtro

Para garantizar la calidad de los datos de la nube de puntos, se evalúan diferentes métodos de filtrado. Estos métodos se analizan en términos de su efectividad para eliminar ruido, mejorar la calidad de la nube de puntos y prepararla para el modelo de predicción. Con base en los resultados obtenidos, se seleccionará el filtro que ofrezca el mejor desempeño.

3.1.2.1. Filtrado de Outliers (SOR)

El filtro de remoción estadística de outliers (*Statistical Outlier Removal*, SOR) utiliza la biblioteca `open3d` para eliminar puntos atípicos o erróneos que pueden haber sido generados por interferencias en la captura de datos.

Algorithm 2 FiltrarSOR

Entrada: puntos, intensidad, return_number, red, green, blue

Salida: puntos_SOR, intensidad_SOR, return_number_SOR, red_SOR, green_SOR, blue_SOR

1. Crear una nube de puntos utilizando las coordenadas
2. Aplicar el filtro de outliers con los parámetros: nb_neighbors = 20 y std_ratio = 2.0
3. Filtrar los puntos y sus propiedades
4. Devolver los puntos y propiedades filtradas

3.1.2.2. Filtrado por Densidad

Se utiliza el método de muestreo por voxel con un tamaño de voxel de 0.1 para reducir la densidad de los puntos y mejorar la eficiencia del procesamiento sin comprometer la representación general de la nube de puntos.

Algorithm 3 FiltrarPorDensidad

Entrada: puntos: Matriz de coordenadas (x, y, z)

Salida: puntos_voxel: Puntos filtrados por densidad

1. Crear una nube de puntos utilizando las coordenadas
2. Aplicar el muestreo por voxel con un tamaño de 0.1
3. Devolver los puntos filtrados

3.1.2.3. Filtrado por Ángulos

Se aplica un filtro basado en la orientación angular de los puntos. Se utiliza un umbral de 45 grados para eliminar puntos mal orientados que no corresponden a la estructura real del objeto.

Algorithm 4 FiltrarPorÁngulos

Entrada: Nube de puntos, Intensidades, Colores (Rojo, Verde, Azul), Umbral de ángulo ($\pi/4$)

Salida: Nube de puntos filtrada por ángulos

1. Estimar las normales de los puntos utilizando búsqueda KNN
2. Establecer un umbral de ángulo de $\pi/4$
3. Filtrar los puntos cuya diferencia angular exceda este umbral
4. Devolver la nube de puntos filtrada.

3.1.2.4. Evaluación y Selección del Filtro

Los filtros aplicados se evalúan con métricas como la cantidad de puntos restantes, la distribución de las coordenadas y la uniformidad de la nube de puntos. El filtro que produzca una nube más limpia y representativa será el seleccionado para el análisis posterior.

3.1.3 Conversión al Formato HDF5

Tras el filtrado, los datos de la nube de puntos se convierten al formato HDF5 para optimizar su organización y facilitar su integración con el modelo DGCNN. Este proceso incluye:

1. Organización de los datos en grupos jerárquicos con coordenadas, valores RGB y etiquetas.
2. Normalización de coordenadas y colores para garantizar consistencia en cada fragmento (*chunk*).

3. Dividir los datos en fragmentos (*chunks*) y asegurarse de que cada fragmento esté normalizado dentro de un rango uniforme.

4. Conversión a un formato compatible con PyTorch, dividiendo los datos en conjuntos de entrenamiento (80 %) y prueba (20 %) para el modelo DGCNN.

5. Almacenamiento de parámetros de normalización (media y desviación estándar) para facilitar la desnormalización si es necesario.

El formato HDF5 no solo optimiza el almacenamiento, sino que también permite que los datos sean utilizados directamente como entrada en el modelo DGCNN. De esta manera, la Unidad 1 completa el preprocesamiento exhaustivo, asegurando que los datos sean precisos, uniformes y estén listos para su análisis en la Unidad 2.

3.2 Unidad 2: Modelo DGCNN

En esta unidad se implementa el modelo de Red Convolucional de Grafos Dinámicos (DGCNN) para la segmentación y segmentación semántica de la nube de puntos preprocesada. Este modelo es particularmente útil para analizar estructuras complejas debido a su capacidad de capturar relaciones locales y globales entre los puntos, lo que lo convierte en una herramienta poderosa para este tipo de datos tridimensionales.

3.2.1 Aplicación del Modelo DGCNN

El modelo *Dynamic Graph Convolutional Neural Network* (DGCNN) se seleccionó por su capacidad de procesar datos no estructurados como nubes de puntos. Este modelo genera gráficos dinámicos que representan las relaciones espaciales entre

los puntos de entrada y los actualiza en cada capa convolucional. Esto permite capturar tanto características locales como globales, mejorando la capacidad del modelo para realizar segmentación y segmentación semántica precisa de la nube de puntos [32].

Los datos preprocesados, almacenados en formato HDF5 durante la Unidad 1, se cargan como entrada del modelo. Estos datos se dividen en fragmentos (*chunks*) que aseguran un procesamiento eficiente, normalizados previamente para garantizar un rango uniforme entre las características.

3.2.2 Entrenamiento y Evaluación del Modelo DGCNN

El modelo DGCNN se entrenó utilizando el algoritmo de optimización *Stochastic Gradient Descent (SGD)*, y se evaluó con métricas específicas para asegurar que cumple con los objetivos planteados. Este proceso se diseñó para maximizar la generalización del modelo y minimizar el sobreajuste en los datos de entrenamiento.

3.2.2.1. Entrenamiento del Modelo

El entrenamiento se lleva a cabo en los siguientes pasos:

1. Construcción del Grafo Dinámico: A partir de los datos de entrada, se calculan los k-vecinos más cercanos para cada punto de la nube, representando sus relaciones espaciales. Este grafo dinámico se actualiza en cada capa convolucional del modelo.
2. Configuración del Modelo:
   - Optimizador: *Stochastic Gradient Descent (SGD)*.
   - Tasa de aprendizaje: 0.001.

- *Momentum*: 0.9.
- Épocas: 100.
- Tamaño de lote (*batch size*): 32 para entrenamiento, 16 para prueba.

3. Regularización: Se aplica un *dropout* del 50 % para reducir el riesgo de sobreajuste.
4. Retropropagación: El modelo ajusta sus pesos minimizando la función de pérdida a través de retropropagación (*backpropagation*).

Este flujo asegura que el modelo aprenda representaciones significativas de los datos, mejorando su capacidad de predicción en datos no vistos.

3.2.2.2. Evaluación del Modelo

La evaluación del modelo se realiza utilizando el conjunto de prueba, previamente separado durante el preprocesamiento. Se emplean métricas clave para evaluar el rendimiento:

- Precisión (*Accuracy*): Evalúa el porcentaje de predicciones correctas sobre el total.
- Recall: Mide la capacidad del modelo para identificar correctamente instancias positivas.
- F1-Score: Calcula el promedio armónico entre precisión y *recall*, siendo útil para conjuntos desbalanceados.
- IoU (Intersección sobre Unión): Evalúa la superposición entre las predicciones y los valores reales.

- Matriz de Confusión: Proporciona un desglose detallado de aciertos y errores para cada clase.

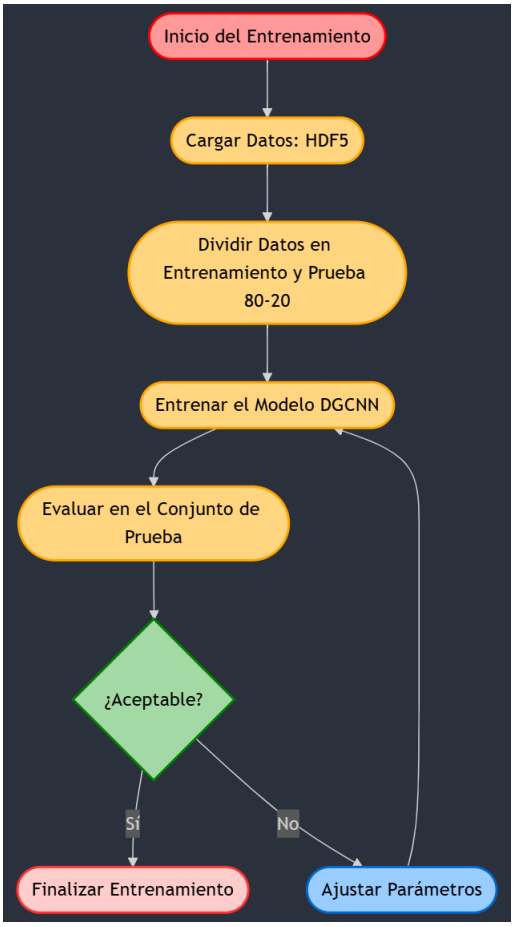

FIGURA 3.2: Diagrama de flujo del proceso de entrenamiento y evaluación del modelo DGCNN

3.2.3 Resultados y Aplicación

El modelo entrenado se utiliza para realizar predicciones sobre las diferentes clases del conjunto de datos. Los resultados se analizan en términos de las métricas calculadas, identificando fortalezas y áreas de mejora.

El modelo DGCNN ha demostrado ser eficiente en la segmentación y segmentación semántica de nubes de puntos, siendo capaz de generalizar sobre datos no vistos y adaptarse a las características intrínsecas de estructuras complejas.

3.3 Unidad 3: Evaluación Ética y Transparencia

La investigación se realizará con total respeto hacia los sitios patrimoniales y las normativas vigentes en cuanto a la privacidad y tratamiento de datos. Se priorizará el uso responsable de las tecnologías de recolección de datos, asegurando que no se dañen los sitios ni se comprometa su integridad durante los estudios. Además, se garantizará la transparencia en cada etapa del proyecto, desde la obtención de los datos hasta la presentación de los resultados.

El uso ético de la tecnología incluye la protección de la información cultural y arquitectónica, evitando la explotación indebida de los datos y fomentando su uso exclusivamente con fines de conservación y restauración.

3.4 Conclusión del Marco Metodológico

Estas tres unidades proporcionan un enfoque integral y metódico para el procesamiento, análisis y conservación del patrimonio arquitectónico peruano. Al integrar procesos avanzados de preprocesamiento de datos, modelos de predicción robustos y una evaluación ética rigurosa, esta metodología garantiza que los resultados obtenidos sean precisos, eficientes y aplicables a diversos entornos de conservación. Además, el compromiso con la transparencia y la ética asegura que el proyecto se realice respetando tanto los valores culturales como los principios de sostenibilidad y conservación responsables.

CAPÍTULO IV

RESULTADOS

En esta sección se presentan los resultados obtenidos mediante la aplicación de la metodología descrita en las tres unidades: el preprocesamiento de la nube de puntos, la implementación y evaluación del modelo DGCNN, y la validación ética y transparente de los resultados. Estos resultados reflejan la eficacia del enfoque propuesto en el análisis y conservación de edificaciones patrimoniales.

Para la experimentación de este trabajo de investigación, se utilizó un archivo .LAS que contiene la nube de puntos de una catedral de patrimonio nacional, como se puede ver en la Figura 4.1. Este archivo fue procesado con el software Cloud Compare, herramienta esencial para convertir los datos a un formato más adecuado para el análisis exploratorio y para alimentar nuestro modelo predictivo.

FIGURA 4.1: Visualización la catedral.

Cloud Compare facilita la conversión entre diferentes tipos de formatos; en nuestro caso, el archivo se transformó a formato TXT. Utilizamos la librería pandas de Python para inspeccionar la cabecera del archivo y realizar un análisis preliminar.

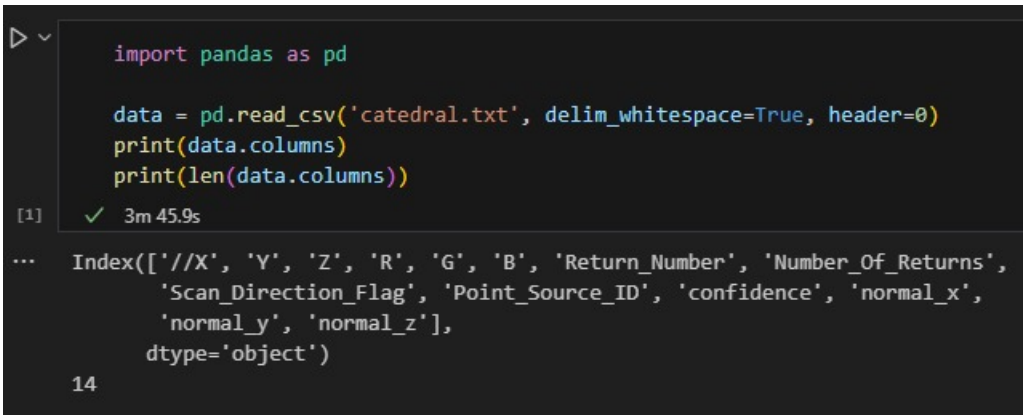

FIGURA 4.2: Visualización de la cabecera del archivo .LAS transformado.

El análisis preliminar mostró 14 atributos para cada punto en el archivo, descritos de la siguiente manera:

Atributo	**Descripción**
X	Coordenada X del punto
Y	Coordenada Y del punto
Z	Coordenada Z del punto
R	Componente roja del color del punto
G	Componente verde del color del punto
B	Componente azul del color del punto
Return Number	Número de retorno del pulso láser
Number Of Returns	Número total de retornos para un pulso láser
Scan Direction Flag	Dirección de escaneo del láser
Point Source ID	Identificador de la fuente del punto
Confidence	Nivel de confianza o precisión del punto
Normal X	Componente X de la normal del punto
Normal Y	Componente Y de la normal del punto
Normal Z	Componente Z de la normal del punto

TABLA 4.1: Descripción de los atributos de cada punto en el archivo.

4.1 Resultados del Preprocesamiento de la Nube de Puntos

Siguiendo los pasos descritos en la Unidad 1 del marco metodológico, se aplicaron diversas técnicas de filtrado para optimizar la calidad de la nube de puntos. Este preprocesamiento es esencial para garantizar que los datos sean adecuados para las etapas posteriores de análisis, como la segmentación y segmentación semánticaón mediante el modelo DGCNN.

El archivo original en formato .LAS contenía 30 millones de puntos, cada uno con 14 atributos clave descritos en la Tabla 4.1. El preprocesamiento se centró en eliminar el ruido y los puntos atípicos para mejorar la precisión y reducir el volumen de datos innecesarios. Para ello, se seleccionó un segmento de la catedral correspondiente al patio, como se observa en la Figura 4.3, con un total de 3.5 millones de puntos.

FIGURA 4.3: Patio de la catedral sin filtros.

4.1.1 Resultados de los Filtros Aplicados

Se aplicaron tres técnicas de filtrado: remoción estadística de outliers (SOR), filtrado por densidad (Voxel Grid) y filtrado por ángulos. Y para una validación visual, los datos filtrados se guardaron en un archivo TXT y se volvieron a cargar en Cloud Compare para evaluar las modificaciones realizadas y comparar con la data original. A continuación, se presentan los resultados de cada método.

4.1.1.1. Filtro SOR (Statistical Outlier Removal)

El filtro SOR se aplicó con los parámetros: 10 vecinos cercanos y un umbral de desviación estándar de 1.0. Este método resultó en la eliminación de 4.9 % de los puntos originales, dejando un total de 3,392,946 puntos para el patio de la catedral. Como se muestra en la Figura 4.4, el filtro logró eliminar puntos ruidosos mientras mantenía la estructura arquitectónica intacta.

FIGURA 4.4: Patio de la catedral después de aplicar el filtro SOR.

4.1.1.2. Filtro por Densidad (Voxel Grid)

El filtrado por densidad se realizó utilizando un tamaño de voxel de 0.1 unidades, lo que permitió reducir significativamente el número de puntos. Aunque este método es eficiente para optimizar el procesamiento, la Figura 4.5 muestra que la reducción de puntos también provocó la pérdida de detalles importantes, comprometiendo la representación arquitectónica.

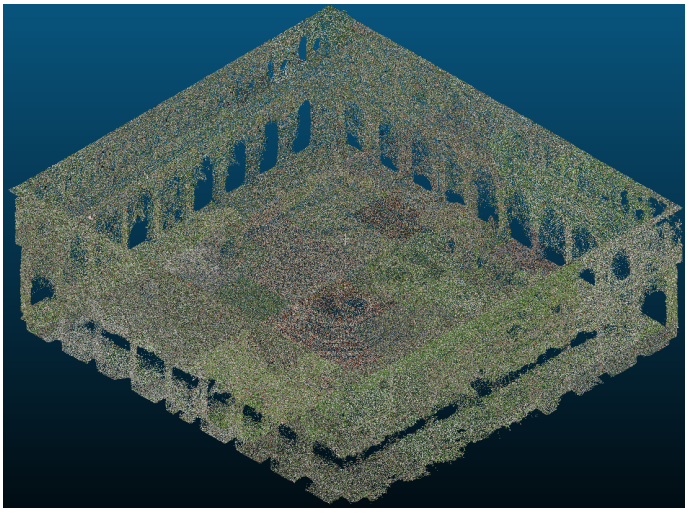

FIGURA 4.5: Reducción de ruido utilizando el filtro por densidad (Voxel Grid).

4.1.1.3. Filtro por Ángulos

El filtrado basado en ángulos se aplicó para eliminar puntos cuya orientación no coincidía con las superficies circundantes, utilizando un umbral de 45 grados. Como se observa en la Figura 4.6, el método fue efectivo para eliminar puntos mal orientados, pero también resultó en la pérdida de información en áreas clave, como esquinas y bordes.

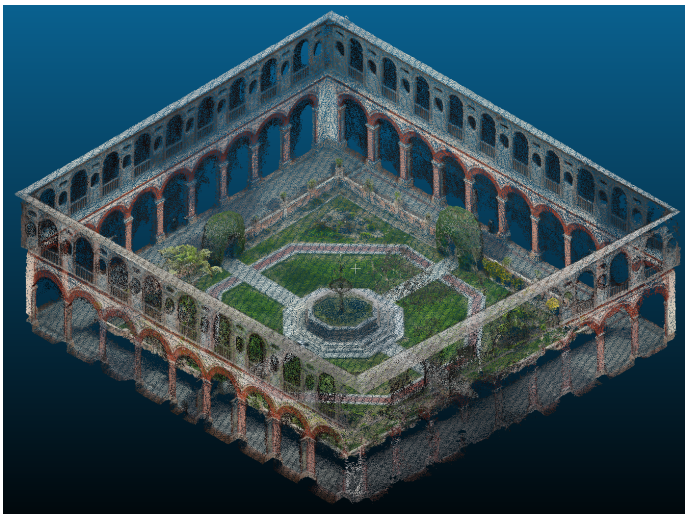

FIGURA 4.6: Reducción de ruido utilizando el filtro por ángulos.

4.1.2 Comparación de Resultados entre Filtros

En la Tabla 4.2, se resumen los resultados obtenidos con cada técnica de filtrado en términos del número de puntos restantes y la preservación de detalles arquitectónicos clave.

Filtro	**Puntos Restantes**	**Preservación de Detalles**
Sin Filtrar	3,567,953	-
SOR	3,392,946	Alta
Voxel Grid	2,874,123	Media
Ángulos	3,112,457	Media

TABLA 4.2: Comparación de los resultados obtenidos con diferentes filtros.

4.1.3 Conclusión de Resultados del Preprocesamiento

Los resultados demuestran que el filtro SOR es la técnica más efectiva para el preprocesamiento de la nube de puntos, ya que elimina el ruido preservando

las características esenciales de la estructura patrimonial. Los métodos alternativos, aunque útiles en ciertos contextos, presentan limitaciones en la preservación de detalles críticos, lo que puede comprometer el rendimiento de los módulos posteriores de análisis y predicción.

4.2 Resultados de la Aplicación del Modelo DGCNN para Segmentación

En esta sección se presentan los resultados del proceso de segmentación de una nube de puntos perteneciente a una catedral patrimonial peruana. La segmentación se llevó a cabo utilizando el modelo DGCNN (Dynamic Graph Convolutional Neural Network) con el objetivo de clasificar cada punto en una de las siguientes categorías arquitectónicas: pared, piso, columna, balcón, arco y otros. Dado el tamaño de los datos, la nube de puntos fue dividida en *chunks*, aplicando métodos de preprocesamiento para normalizar cada fragmento de forma independiente.

4.2.1 Preparación de los Datos y Preprocesamiento

Los datos en formato .LAS fueron convertidos a .H5 y segmentados en *chunks* de tamaño manejable. Cada fragmento fue normalizado de forma independiente para garantizar que todos los datos de entrada al modelo estuvieran en un rango uniforme, facilitando la convergencia durante el entrenamiento.

Algorithm 5 Proceso de normalización de un archivo .LAS

Entrada: `las_file_path`: Ruta del archivo .LAS

Salida: Coordenadas normalizadas, colores normalizados y etiquetas

1. **Leer archivo LAS:** Cargar el archivo usando `laspy`.
2. **Extraer datos:** Obtener coordenadas (x, y, z) y, si están presentes, colores (r, g, b). Asignar valores predeterminados a los colores si no están disponibles.
3. **Calcular estadísticos:** Calcular media y desviación estándar para las coordenadas y colores.
4. **Normalizar datos:** Aplicar la normalización a cada coordenada y componente de color mediante:

$$\text{valor_normalizado} = \frac{\text{valor} - \text{media}}{\text{desviación estándar}}$$

5. **Salida:** Retornar las coordenadas y colores normalizados junto con las etiquetas.

4.2.2 Arquitectura del Modelo DGCNN

El modelo DGCNN se adapta a datos de nubes de puntos al capturar relaciones locales y globales entre los puntos. A través de la construcción dinámica de un grafo k-NN (k-Nearest Neighbors), el modelo puede comprender la estructura espacial de los datos.

Algorithm 6 Proceso de inferencia en el modelo DGCNN

Entrada: Datos de entrada x

Salida: Predicciones de clase para cada punto

1. Calcular índices de vecinos más cercanos k (`idx` = `knn`(x, k)).
2. Extraer características del gráfico utilizando k-NN (`x` = `get_graph_feature`(x, idx)).
3. Pasar x a través de capas convolucionales y de activación ReLU.
4. Concatenar características locales y calcular la predicción final.

4.2.3 Entrenamiento del Modelo

El modelo DGCNN se entrenó mediante la técnica de *mini-batch*, utilizando métricas como IoU (Intersection over Union), precisión, *recall* y F1 Score para evaluar su rendimiento en cada época. La pérdida se calculó mediante entropía cruzada ponderada para manejar el desbalance de clases.

Algorithm 7 Proceso de entrenamiento del modelo DGCNN

Entrada: Dataset en batches, modelo DGCNN, épocas, tasa de aprendizaje

Salida: Modelo entrenado

Inicializar modelo, optimizador (Adam) y escalador de gradiente.

Configurar dispositivo (`cuda` si está disponible).

para *cada época en* `num_epochs` **hacer**

- Establecer el modelo en modo entrenamiento.
- Inicializar `total_loss`, `total_correct`, `total_samples` a 0.
- **para** *cada batch en* `train_loader` **hacer**
  - Cargar datos en dispositivo y reiniciar gradientes.
  - Pasar datos al modelo, calcular pérdida (entropía cruzada).
  - Escalar y retropropagar pérdida, actualizar parámetros.
  - Acumular pérdida y precisión del batch.
- Calcular y almacenar pérdida promedio y precisión de la época.
- `// Evaluación en validación`
- Calcular métricas de IoU, precisión, `recall` y F1-score.
- Actualizar tasa de aprendizaje; guardar modelo si IoU mejora.

4.2.4 Resultados de los experimentos

En primer lugar, se etiquetó el patio de la catedral como se puede ver en la Figura 4.7, luego dividimos esta nube en 4 partes y seleccionamos una parte del patio de la catedral en la Figura 4.8 para el entrenamiento del modelo. Esta nube de entrenamiento muestra la sección del patio de la catedral, la cual está segmentada con diferentes colores para representar los elementos arquitectónicos. Los rojos correspondes a las paredes, en este caso, aparecen como superficies verticales y planas. Se logra una presencia uniforme de los puntos para esta clase. Los puntos verdes

representan a los arcos; estos tienen una forma curvilínea distintiva y se encuentran por encima de las columnas (para la estructura forman el soporte continuo entre estas y las paredes, también se logra cubrir esta clase. Ahora, el color amarillo atribuido a la clase columnas, presenta a estos elementos verticales que actúan como soportes estructurales transfiriendo la carga de los arcos hacia el suelo. Para esta clase, se observa ausencia de puntos en la columna de esquina.

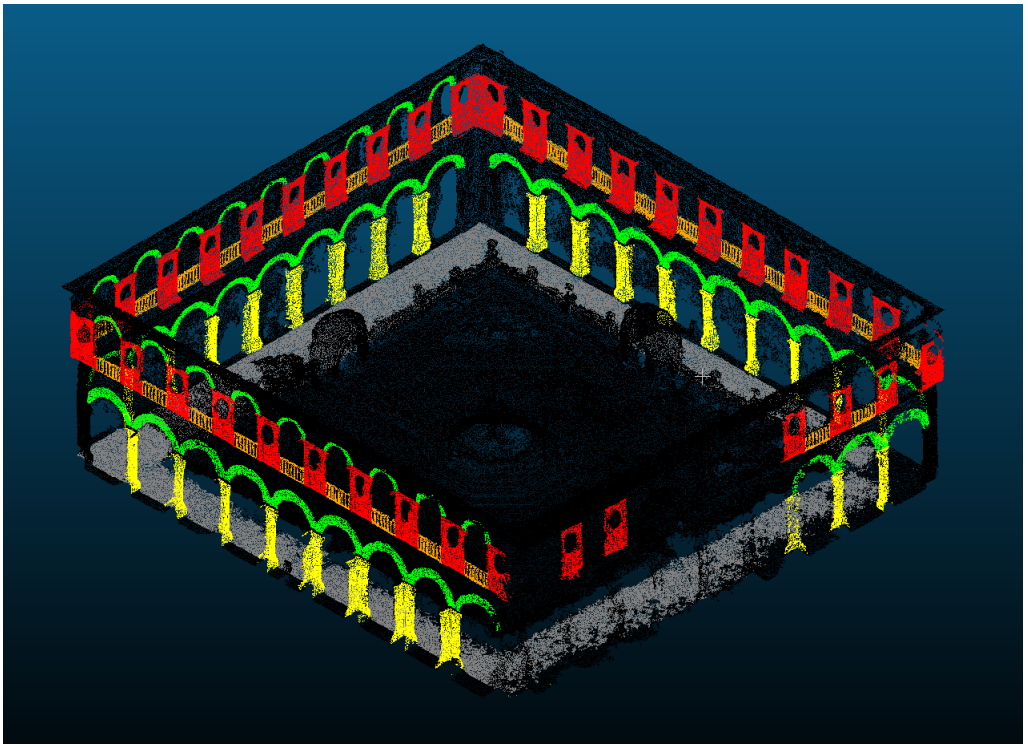

FIGURA 4.7: Etiquetas verdaderas visualizadas en Cloud Compare.

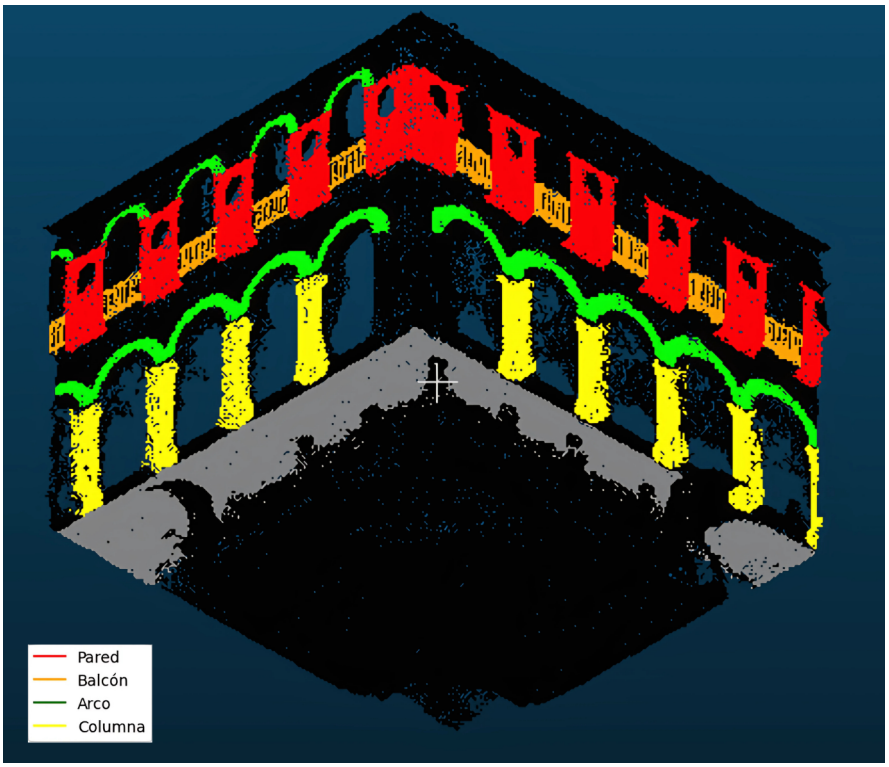

FIGURA 4.8: Nube de entrenamiento de una seccion del patio.

Luego de entrenar el modelo se realizó una predicción en todo el patio de la catedral.

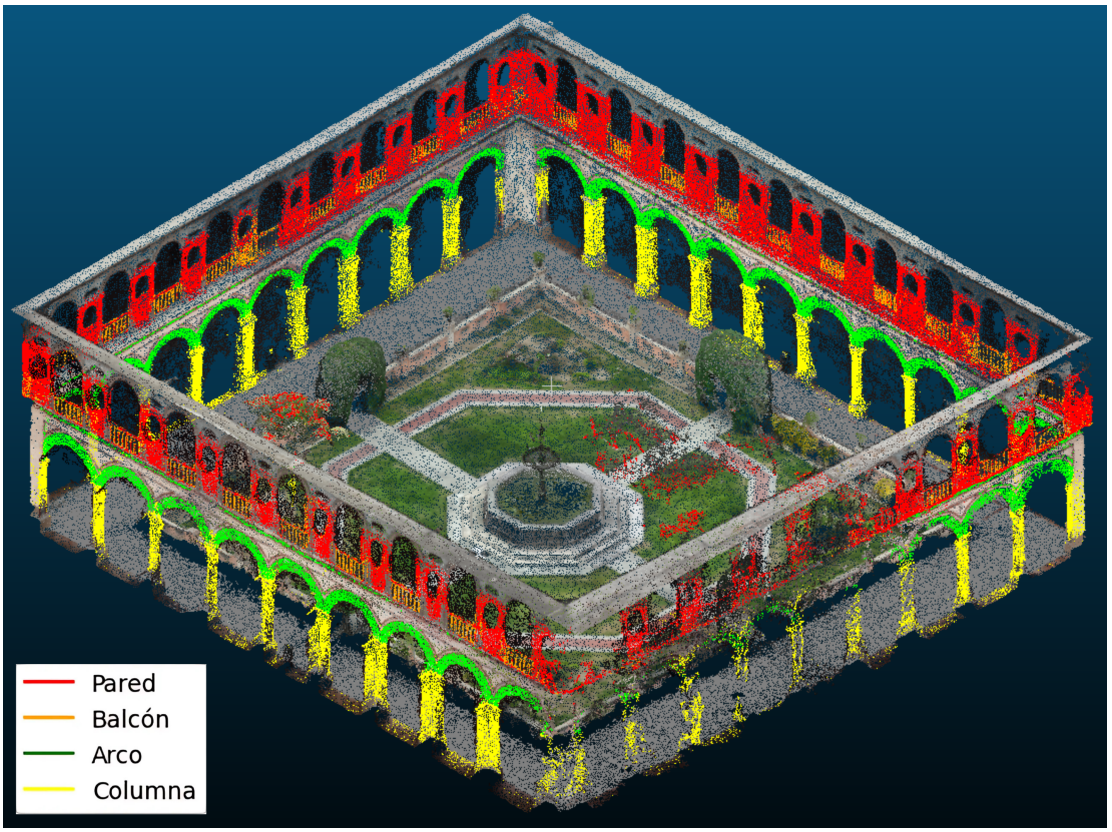

FIGURA 4.9: Nube de predicha del patio.

En esta figura 4.9 se observa el resultado de segmentación aplicado al patio de la catedral. Se puede observar que por parte de las estructura mejor clasificadas son las columnas que se esta realizando mejor la segmentación en este tipo de estructura. Inclusive en la parte donde existe perdida de información el modelo logra identificar que se trata de columnas. Con respecto a las paredes el modelo tiene algunas confusiones ya que pinta las hojas de los arboles como rojo. En la detección de los arcos representados por el color verde el modelo logra hacer una identificación adecuada.

Luego, utilizando el modelo entrenado exclusivamente con la sección del patio, se realizó una predicción sobre la nube de puntos correspondiente a una capilla de la catedral.

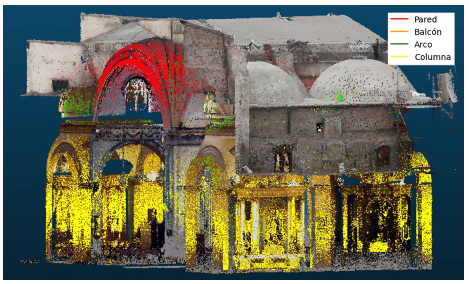

FIGURA 4.10: Nube de predicha de una capilla de la catedral con el modelo entrenado solo con el patio.

FIGURA 4.11: Sección de la nube predicha de la capilla de la catedral.

Como se puede observar en la Figura 4.10, el modelo muestra limitaciones claras debido al sobreajuste al conjunto de datos del patio. Las paredes son parcialmente identificadas, pero las columnas y los arcos son mal segmentados o ignorados. Las columnas, al ser más estilizadas y con proporciones diferentes a las del patio, no son reconocidas correctamente. El modelo tiene dificultades para detectar estructuras en esta nube de puntos, esto debido a un sobre ajuste del modelo ya que este solamente se entreno con el patio de la catedral. Además, los arcos presentan problemas debido a diferencias en la geometría (por ejemplo, formas más altas o anchas en la capilla). Ahora, la Figura 4.11 muestra una vista transversal de la capilla, donde las paredes están dominando la segmentación. Lo arcos no son muy reconocible y las columnas son inconsistentes. La distribución incorrecta de los colores sugiere que el modelo tiene dificultades para interpretar las relaciones geométricas y espaciales de la capilla, como la alineación entre los arcos y columnas, que aquí aparecen desconectados.

Como el resultado para las figuras previas no fue óptimo debido al sobreajuste, se resolvió proporcionando un nuevo conjunto de datos al modelo como se pueder ver en las Figuras 4.12 y 4.13.

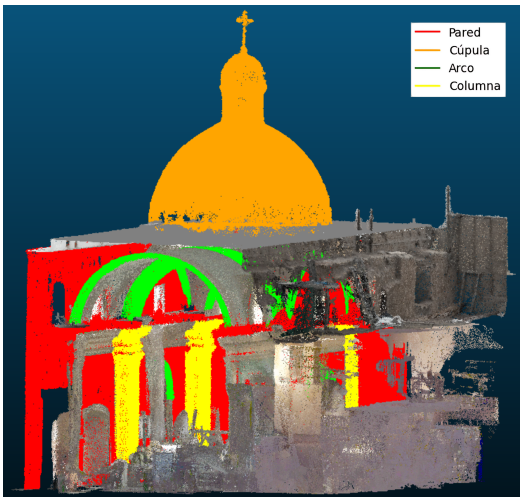

FIGURA 4.12: Nube de puntos de la capilla etiquetada manualmente para el entrenamiento.

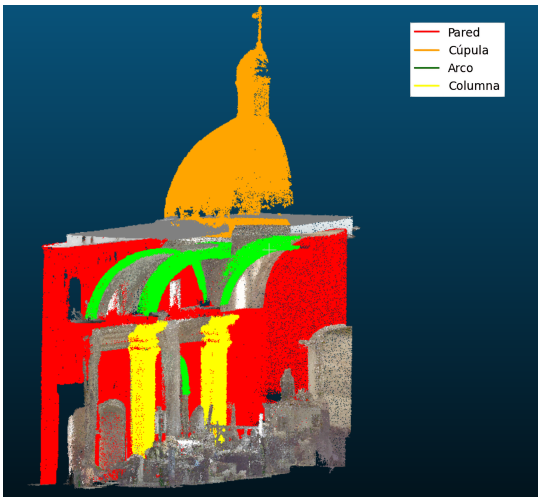

FIGURA 4.13: Sección de la nube de puntos de la capilla etiquetada manualmente para el entrenamiento.

Luego de entrenar al modelo con esta nube de puntos se obtuvo los resultados de la Figura 4.14.

(a) Nube de puntos 1.

(b) Nube de puntos 2.

(c) Nube de puntos 3.

(d) Corte transversal 1.

(e) Corte transversal 2.

(f) Corte transversal 3.

FIGURA 4.14: Nubes de puntos obtenidas en la experimentación

Para las Figuras 4.14 (a), Figura 4.14 (b) y Figura 4.14 (c), estas vistas generales destacan las paredes, que están etiquetadas de manera más uniforme y continua, representando correctamente las superficies verticales que delimitan la estructura de la capilla. Los arcos son más visibles en comparación con predicciones anteriores, mostrando su forma curva en las intersecciones entre paredes y columnas. Las columnas están mejor segmentadas, apareciendo como soportes verticales que conectan las bases con los arcos. Las cúpulas anaranjadas son difíciles de identificar en las vistas (b) y (c). Ahora, para las Figuras 4.14 (d), Figura 4.14 (e) y Figura 4.14 (f) en los cortes transversales, las paredes continúan siendo el elemento más claro, con una delimitación precisa de las superficies interiores y exteriores. Los arcos son reconocibles en algunos puntos, pero su continuidad no es consistente en todas las áreas, lo que indica que el modelo aún tiene dificultades en las geometrías más complejas. Las columnas se ven con mayor claridad como elementos verticales separados, aunque en algunas áreas parecen incompletas debido a la distribución irregular de los puntos. Las cúpulas, son más visibles.

4.2.5 Métricas de Evaluación por Clase

La gráfica (Figura 4.15) muestra la evolución del IoU (Intersection over Union) por clase durante las épocas de entrenamiento del modelo de DGCNN, reflejando diferentes patrones en el desempeño de cada categoría. Las clases *otro* y *piso* destacan por mantener un IoU relativamente alto y estable, lo que indica consistencia y precisión en su segmentación, mientras que *columna* y *pared*, aunque con buen desempeño general, presentan mayor variabilidad, sugiriendo ligeras dificultades para generalizar las estructuras. Por otro lado, la clase *balcón* muestra un IoU mucho más bajo y fluctuante, lo que podría indicar que la clase presenta características complejas para el modelo. La clase *arco* también muestra IoUs menos estables, con

picos y caídas significativas que podrían derivar de limitaciones del modelo para diferenciarlas correctamente. En términos generales, todas las clases muestran mejoras al inicio del entrenamiento mientras el modelo aprende las características principales de los datos; sin embargo, a medida que el entrenamiento avanza, las clases con bajo IoU siguen presentando dificultades, mientras que las de alto IoU se estabilizan, reflejando el potencial del modelo para ciertas categorías y las áreas que aún requieren optimización.

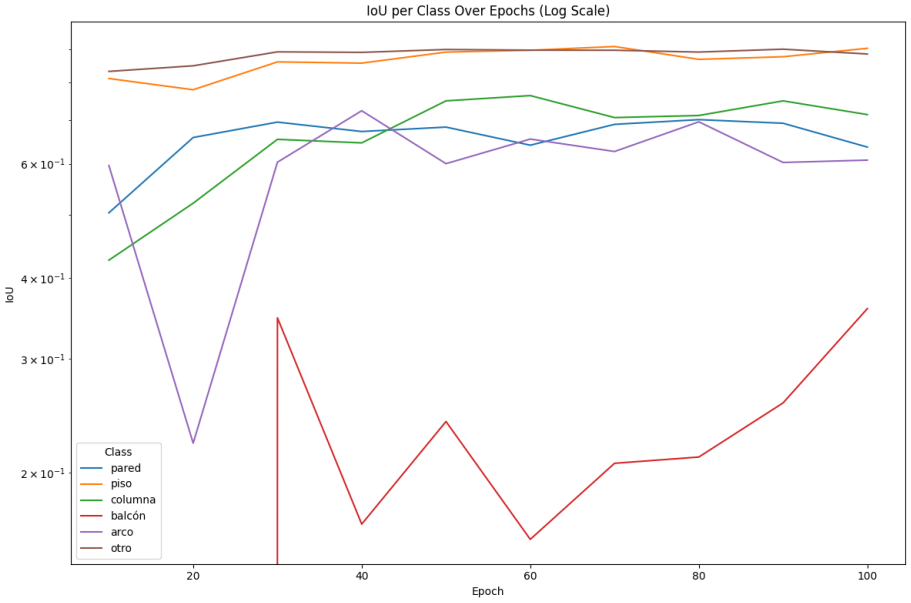

FIGURA 4.15: IoU por clase a lo largo de las épocas.

4.2.6 Métricas de Validación Generales

El análisis de las métricas de validación (Figura 4.16) revela diferentes comportamientos en el desempeño del modelo. El IoU comienza con valores bajos pero muestra un aumento significativo en las primeras épocas, estabilizándose alrededor de la época 30-40, aunque con cierta variabilidad, lo que indica que el modelo aprende rápidamente a identificar las regiones relevantes; sin embargo, enfrenta dificultades para mejorar la segmentación en etapas posteriores. Por otro lado, las métricas de

precisión, *recall* y F1 Score presentan valores iniciales más altos que el IoU y evolucionan de manera más uniforme, alcanzando estabilidad entre las épocas 20-30. La alta precisión sugiere que el modelo realiza predicciones correctas con poca incidencia de falsos positivos, mientras que el alto *recall* indica que identifica correctamente la mayoría de las regiones de interés. El F1 Score ayuda a confirmar el desempeño equilibrado del modelo. Sin embargo, el IoU, al penalizar tanto falsos positivos como falsos negativos de manera más severa, se mantiene más bajo, lo que podría reflejar dificultades del modelo en segmentar áreas pequeñas o clases más complejas. En general, las métricas muestran que el modelo clasifica y detecta bien, pero se podría mejorar la precisión de la segmentación en clases más desafiantes.

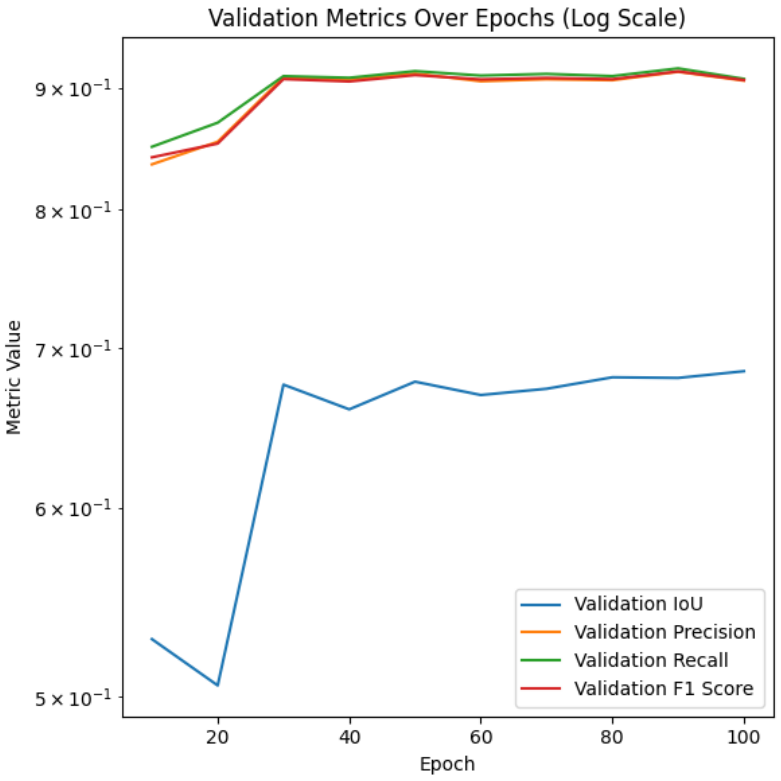

FIGURA 4.16: Métricas de validación a lo largo de las épocas (IoU, Precisión, Recall, F1).

4.2.7 Matriz de Confusión

La matriz de confusión (Figura 4.17) revela un desempeño variado entre las clases, destacando resultados elevados en algunas categorías y confusiones significativas en otras. La clase *piso* se distingue con una precisión muy alta (94.28 %), mostrando que el modelo predice correctamente la mayoría de los casos, seguida de la clase *otro*, que también alcanza un desempeño destacado (90.83 %) con mínimas confusiones hacia otras categorías. Sin embargo, la clase *balcón* enfrenta grandes desafíos, con una precisión baja (34.79 %) y confusiones significativas hacia *pared* (40.74 %) y *otro* (24.47 %), reflejando la complejidad para identificar dicha estructura. De manera similar, la clase *arco* muestra confusiones notables hacia *otro* (26.15 %), posiblemente debido a características visuales compartidas. Las clases con desempeño moderado, como *columna* (81.30 %), también presentan confusiones hacia *otro* (18.02 %), mientras que *pared* (75 %) tiene confusiones menores hacia *otro* (20.79 %) y *balcón* (4.19 %). En general, el modelo muestra un buen desempeño en clases como *piso*, *otro* y *columna*, pero enfrenta dificultades para distinguir con precisión estructuras más complejas como *balcón* y *arco*.

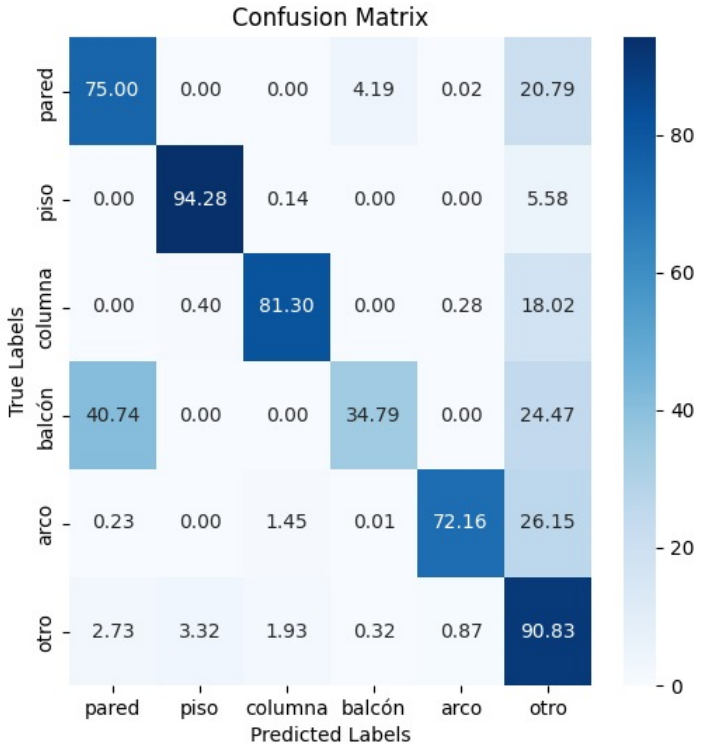

FIGURA 4.17: Matriz de confusión para la segmentación de la nube de puntos.

4.3 Discusión de Resultados

Los resultados obtenidos en este trabajo de investigación destacan tanto las fortalezas como las limitaciones del enfoque propuesto, lo que permite contextualizar su efectividad en el análisis de edificaciones patrimoniales.

En el preprocesamiento, el filtro SOR demostró ser el método más efectivo para eliminar puntos atípicos, manteniendo la integridad de las características arquitectónicas clave con una pérdida mínima de datos (4.9 %). Por otro lado, el filtro por densidad (Voxel Grid) redujo significativamente la cantidad de puntos, pero a costa de una pérdida de detalles importantes, mientras que el filtro por ángulos

presentó resultados intermedios, eliminando puntos mal orientados, aunque también afectando elementos geométricos clave como esquinas y bordes.

El desempeño del modelo DGCNN fue efectivo en la segmentación de elementos arquitectónicos clave en el patio de la catedral. Las columnas y los arcos fueron segmentados con mayor precisión, mientras que las paredes presentaron algunas confusiones con elementos no arquitectónicos, como vegetación. Este comportamiento resalta la capacidad del modelo para generalizar en estructuras regulares, aunque su sensibilidad a características geométricas adicionales plantea desafíos en contextos más complejos.

Cuando el modelo entrenado en el patio se aplicó a la capilla, se evidenciaron limitaciones significativas debido al sobreajuste. Las confusiones en la identificación de columnas y arcos reflejan la necesidad de conjuntos de datos de entrenamiento más diversos para representar adecuadamente las geometrías de diferentes partes de la estructura.

Las métricas de validación, como IoU, precisión, *recall* y F1 Score, mostraron un desempeño general positivo, con mayor estabilidad en las clases principales (*piso* y *otro*). Sin embargo, las clases más complejas, como *balcón* y *arco*, presentaron fluctuaciones en sus valores de IoU, lo que indica que el modelo enfrenta dificultades al segmentar estructuras con menos representación en el conjunto de datos.

Finalmente, el análisis de la matriz de confusión confirma estos hallazgos. Clases como *piso* y *otro* lograron precisiones elevadas (94.28 % y 90.83 %, respectivamente), mientras que clases como *balcón* y *arco* tuvieron confusiones significativas hacia otras categorías. Esto destaca la importancia de diversificar el conjunto de datos y mejorar la capacidad del modelo para diferenciar entre estructuras arquitectónicas similares.

En general, los resultados obtenidos evidencian el potencial del modelo DGCNN para aplicaciones en conservación patrimonial, al mismo tiempo que subrayan las áreas que requieren optimización para lograr una segmentación más precisa y robusta.

REFERENCIAS BIBLIOGRÁFICAS

[1] Ministerio de Cultura del Perú, "La ocupación ilegal en Chan Chan," 2020. [Online]. Available: https://www.cultura.gob.pe/

[2] UNESCO, "Machu Picchu: amenazas naturales y conservación," 2021. [Online]. Available: https://whc.unesco.org/en/news/

[3] Z. Wu, S. Chen, L. Yi, and D. Metaxas, "Point cloud processing via recurrent set encoding," *arXiv preprint arXiv:1911.10729*, 2019. [Online]. Available: https://arxiv.org/abs/1911.10729

[4] R. Pierdicca, M. Paolanti, F. Matrone, M. Martini, C. Morbidoni, E. S. Malinverni, E. Frontoni, and A. M. Lingua, "Point cloud semantic segmentation using a deep learning framework for cultural heritage," *Remote Sensing*, vol. 12, no. 6, p. 1005, Mar. 2020. [Online]. Available: http://dx.doi.org/10.3390/rs12061005

[5] R. Mousa, M. Khezli, M. Azadi, V. Nikoofard, and S. Hesaraki, "Classifying objects in 3d point clouds using recurrent neural network: A gru lstm hybrid approach," *Pending confirmation*, March 2024.

[6] B. Haznedar, R. Bayraktar, A. Öztürk, and Y. Arayici, "Implementing pointnet for point cloud segmentation in the heritage context," *Heritage Science*, vol. 11, p. 2, 01 2023.

[7] H. Song, G. Selim, and Y. Gao, "Smart heritage practice and its characteristics based on architectural heritage conservation—a case study of the management platform of the shanghai federation of literary and art circles china," *Sustainability*, vol. 15, p. 16559, 12 2023.

[8] H. Macher, T. Landes, and P. Grussenmeyer, "From point clouds to building information models: 3d semi-automatic reconstruction of indoors of existing buildings," *Applied Sciences*, vol. 7, no. 10, p. 1030, Oct. 2017. [Online]. Available: http://dx.doi.org/10.3390/app7101030

[9] V. Croce, G. Caroti, A. Piemonte, L. De Luca, and P. Véron, "H-bim and artificial intelligence: Classification of architectural heritage for semi-automatic scan-to-bim reconstruction," *Sensors*, vol. 23, no. 5, 2023. [Online]. Available: https://www.mdpi.com/1424-8220/23/5/2497

[10] L. Yang, X. Rong, and Z. Liu, "Enhancing the accuracy of 3d object classification with recurrent neural networks," *Journal of Computer and System Sciences*, vol. 58, no. 2, pp. 307–317, 2019.

[11] S. Xie, J. Wang, and L. Zhao, "Advanced preprocessing techniques for point clouds in architectural heritage," *Journal of Cultural Heritage*, vol. 43, pp. 192–204, 2020.

[12] G. Chen, X. Zhang, and W. Li, "Adaptive interfaces for hbim software based on neural networks," *Automation in Construction*, vol. 112, p. Article 103094, 2021.

[13] A. Alby and E. Otros, "Técnicas de escaneo láser en topografía 3d," *Revista de Topografía*, 2019.

[14] B. Barba and F. Otros, "Fotogrametría digital: aplicaciones y avances," *Tecnologías Geoespaciales*, 2019.

[15] R. Riveiro and L. Lindenbergh, "Nuevas metodologías en topografía 3d," *Revista de Ingeniería Civil*, 2019.

[16] B. Böhler and M. Marbs, "Avances en representación de edificios mediante topografía 3d," *Tecnologías de la Construcción*, 2004.

[17] M. Masiero and N. Otros, "Aplicaciones modernas de la fotogrametría en topografía 3d," *Revista de Cartografía*, 2019.

[18] R. Brumana and S. Otros, "Beneficios del bim para la representación de edificios históricos," *Revista de Patrimonio Cultural*, 2019.

[19] B. Barazzetti and T. Otros, "Análisis estructural mediante modelos bim para edificios patrimoniales," *Revista de Ingeniería Estructural*, 2015.

[20] D. Dore and U. Otros, "Avances en análisis estructural mediante bim," *Revista de Ingeniería Civil*, 2015.

[21] K. Korumaz and V. Otros, "Bim en obras de construcción de edificios históricos," *Revista de Restauración*, 2017.

[22] K. Kumar and C. Cheng, "Gestión de instalaciones en edificios patrimoniales mediante bim," *Revista de Gestión de Instalaciones*, 2015.

[23] B. Biagini and W. Otros, "Restauración de edificios históricos con bim," *Revista de Restauración*, 2016.

[24] T. Trizio and X. Otros, "Aplicaciones de bim en la restauración de edificios patrimoniales," *Revista de Conservación del Patrimonio*, 2019.

[25] K. Kang and H. Hong, "Gestión de instalaciones con bim en edificios históricos," *Revista de Gestión de Instalaciones*, 2015.

[26] D. Della Torre, "Dificultades en la representación de elementos arqueológicos con bim," *Revista de Arqueología*, 2012.

[27] C. Cuca and B. Barazzetti, "Retos en la representación de elementos antiguos con bim," *Revista de Arqueología*, 2019.

[28] F. Fazio and L. Lo Brutto, "Ventajas de los modelos hbim en arqueología," *Revista de Arqueología*, 2019.

[29] G. Georgopoulos and H. Otros, "Explorando el potencial de los modelos hbim en arqueología," *Revista de Arqueología*, 2018.

[30] R. Russo and I. Otros, "Hbim en la representación de elementos históricos," *Revista de Patrimonio Cultural*, 2011.

[31] V. Valente and J. Otros, "Interactividad de los modelos hbim en arqueología," *Revista de Arqueología Digital*, 2017.

[32] Y. Wang, Y. Sun, Z. Liu, S. E. Sarma, M. M. Bronstein, and J. M. Solomon, "Dynamic graph CNN for learning on point clouds," *CoRR*, vol. abs/1801.07829, 2018. [Online]. Available: http://arxiv.org/abs/1801.07829